카드 이탈 데이터에 기반한 이탈 고객 예측 모델링

05기 윤지현

프로젝트 개요

◆ 분석 주제 선정 배경

카드 데이터 = 사람과 가장 가까운 데이터

◆ 분석 목적

카드 이탈 징후를 보이는 고객을 찾아내는 모델을 구축한다.

⟶ ‘어떤 사람’이 카드를 해지할 것인가?

데이터셋 설명

Kaggle

Credit Card customers

Predict Churning customers

BankChurners.csv (1.51 MB)

Detail Compact Column 10 of 23 columns

About this file Suggest Edits

PLEASE IGNORE THE LAST 2 COLUMNS (NAIVE BAYES CLAS...). I SUGGEST TO RATHER DELETE IT BEFORE DOING ANYTHING**

A business manager of a consumer credit card portfolio is facing the problem of customer attrition. They want to analyze the data to find out the reason behind this and leverage the same to predict customers who are likely to drop off.

# CLIENTNUM	Attrition_Flag	# Customer_Age	Gender	# Dependent_count	Educat
Client number. Unique identifier for the customer holding the account	Internal event (customer activity) variable - if the account is closed then 1 else 0	Demographic variable - Customer's Age in Years	Demographic variable - M=Male, F=Female	Demographic variable - Number of dependents	Demogra Educatior of the acc (example college g
708m 828m	Existing Customer 84% Attrited Customer 16%	26 73	F 53% M 47%	0 5	Graduate High Sch Other (49

https://www.kaggle.com/datasets/sakshigoyal7/credit-card-customers

This dataset consists of **10,000 customers** mentioning their age, salary, marital_status, credit card limit, credit card category, etc.

There are **23 features**.

We have only **16.07%** of customers who have churned.

데이터셋 설명

✏️ **고객 식별 및 타겟 변수**

- CLIENTNUM: 고객 번호 (고유 식별자)
- Attrition_Flag: 이탈 여부 (해지하면 1, 유지 중이면 0)

✏️ **인구통계학적 변수**

- Customer_Age: 나이 (만 나이)
- Gender: 성별
- Dependent_count: 부양가족 수
- Education_Level: 학력 수준 (예: 고졸, 대졸, 대학원 등)
- Matiral_Status: 결혼 상태 (기혼, 미혼, 이혼, 미상)
- Income_Category: 연 소득 (소득 구간)

✏️ **카드/상품 관련 변수**

- Card_Category: 카드 등급 (Blue, Silver, Gold, Platinum)
- Months_on_book: 거래 유지 기간 (개월 단위)
- Total_Relationship_Count: 보유한 은행 상품의 총 개수
- Months_Inactive_12_mon: 최근 12개월 중 카드 사용이 없던 개월 수
- Contacts_Count_12_mon: 최근 12개월 고객센터 접촉 횟수
- Credit_Limit: 신용카드 한도 금액
- Total_Revolving_Bal: 총 리볼빙 잔액 (결제하지 않고 이월된 금액)
- Avg_Open_To_Buy: 최근 12개월 평균 사용 가능한 잔여 한도 (신용한도-사용금액)
- Total_Amt_Chng_Q4_Q1: 4분기 대비 1분기 거래 금액 변화율
- Total_Trans_Amt: 최근 12개월 총 거래 금액
- Total_Trans_Ct: 최근 12개월 총 거래 횟수
- Total_Ct_Chng_Q4_Q1: 4분기 대비 1분기 거래 횟수 변화율
- Avg_Utilization_Ratio: 평균 카드 사용률 (사용금액/신용한도)

EDA 요약

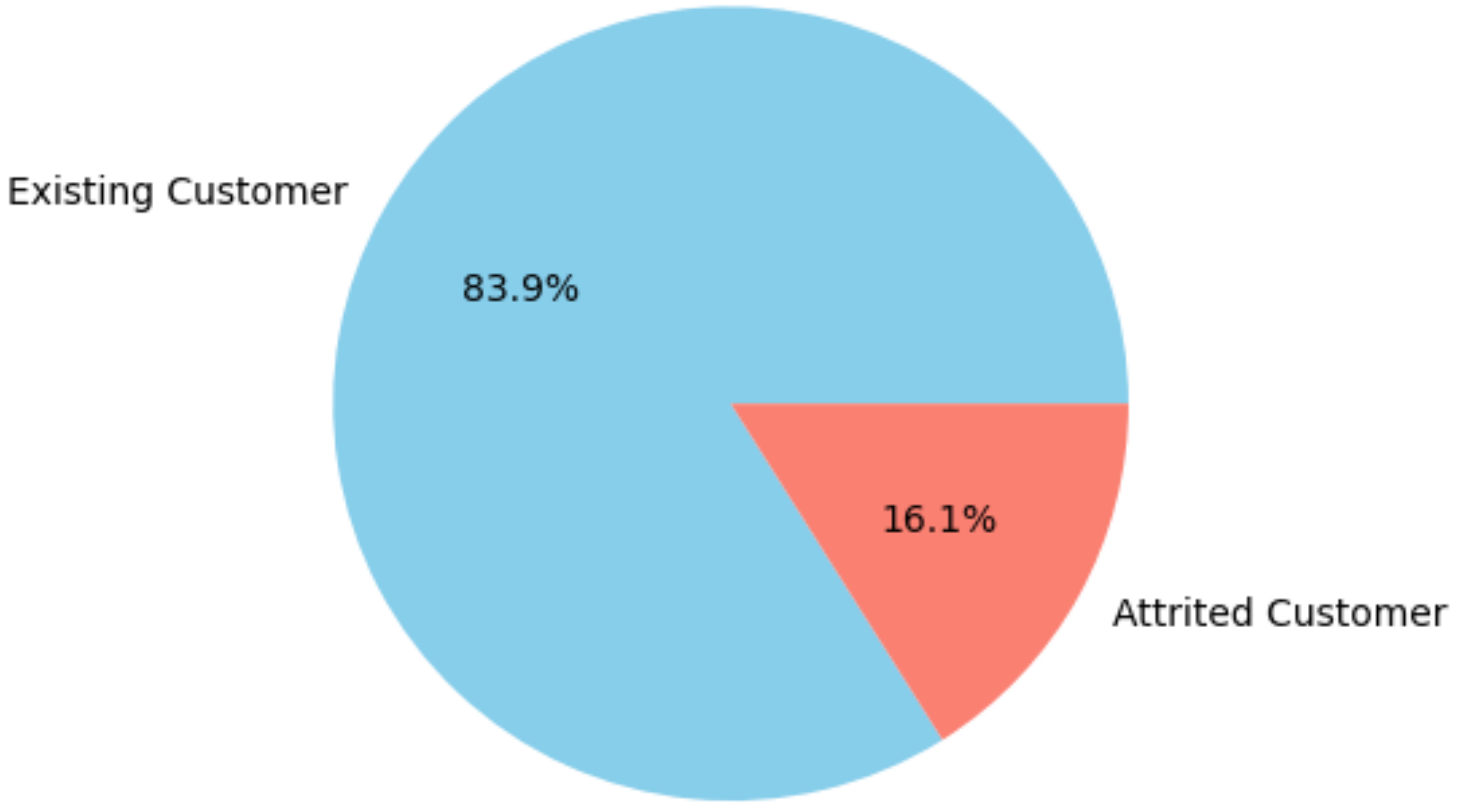

EDA 요약

표본 수가 너무 적은 데이터

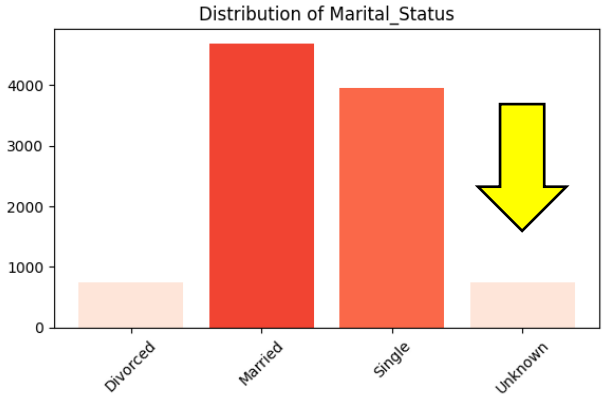

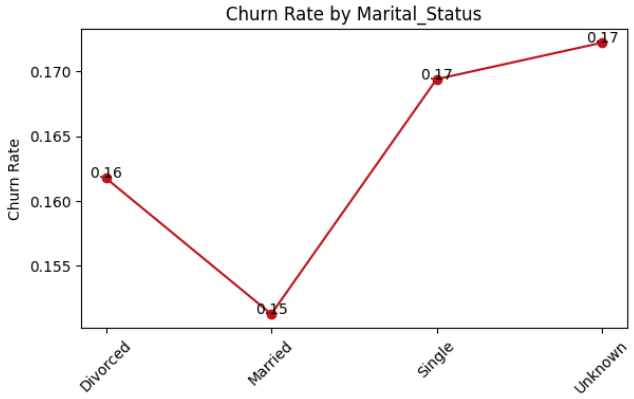

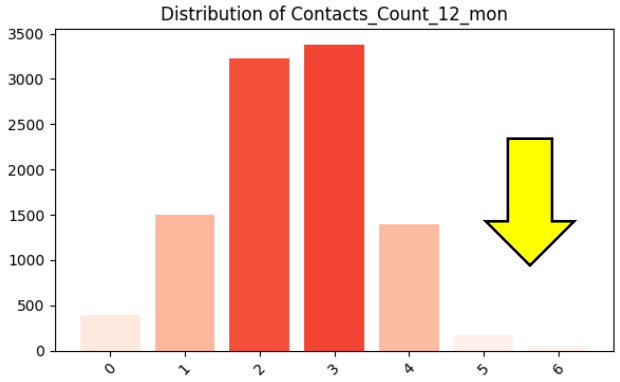

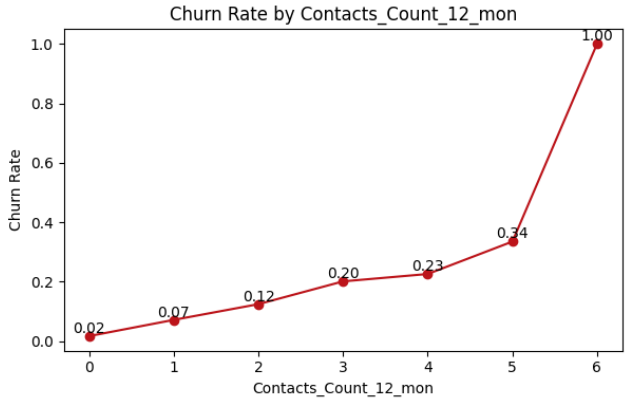

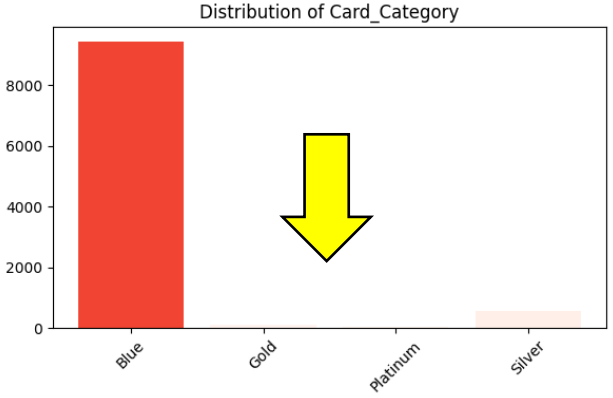

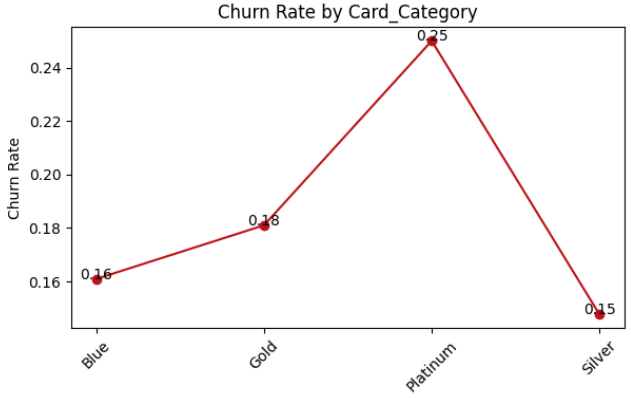

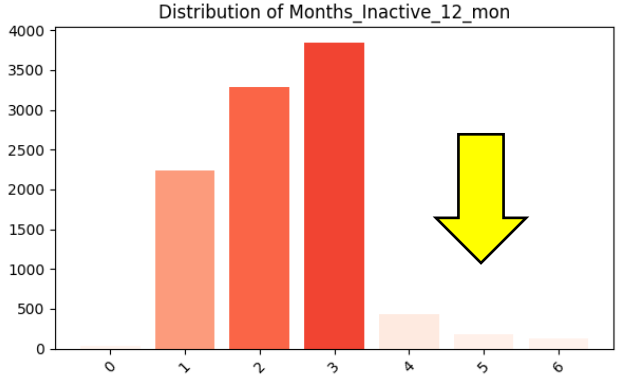

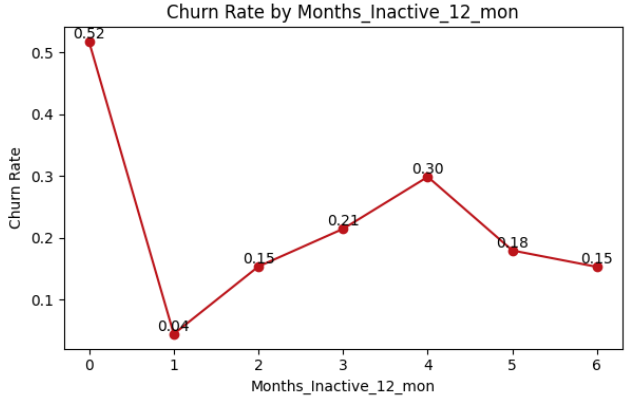

EDA 요약

Unknown

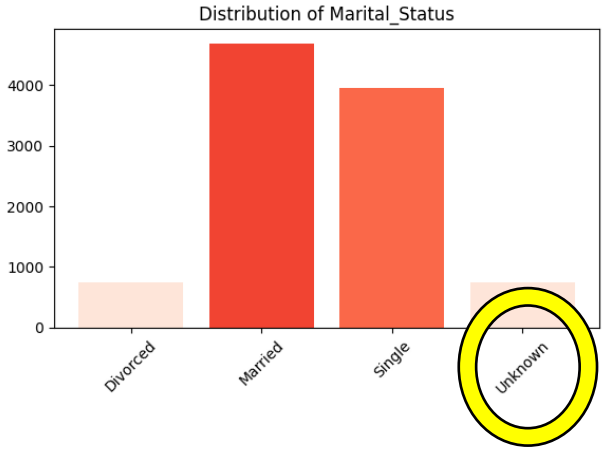

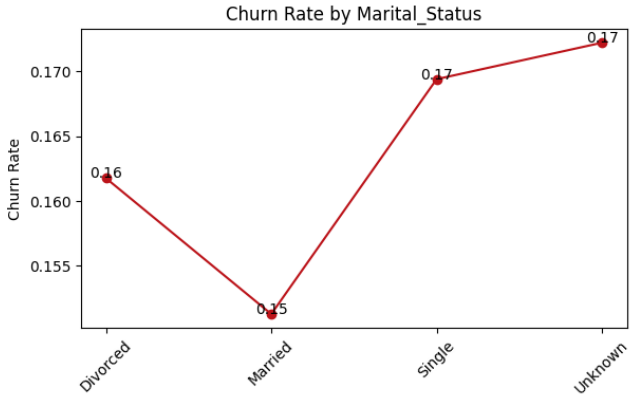

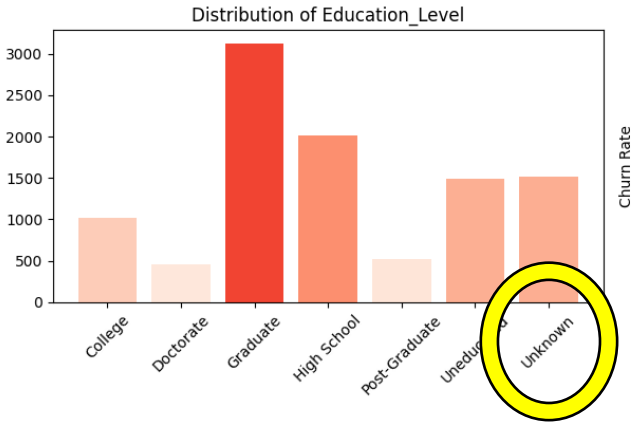

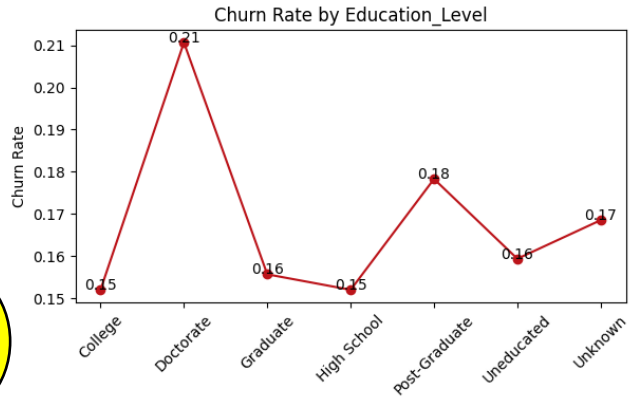

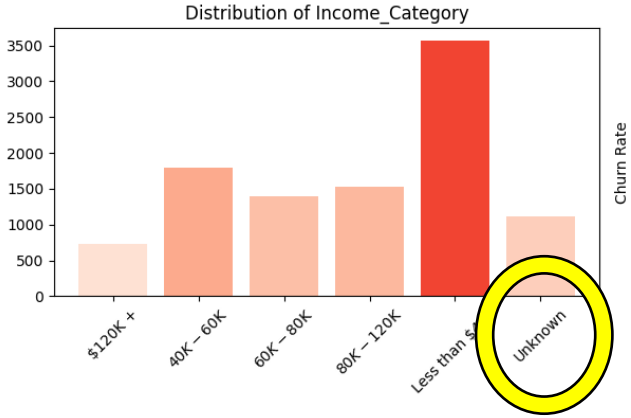

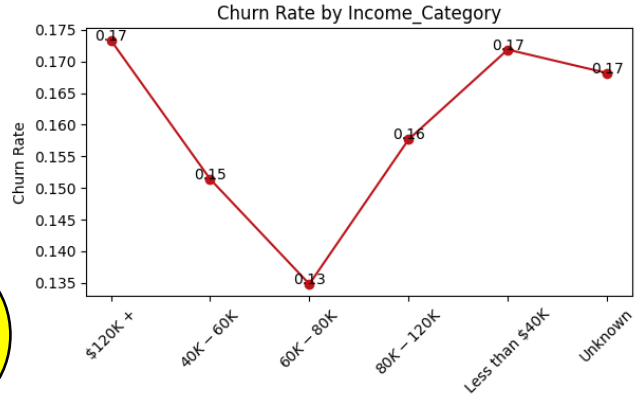

정보 미제공 자체가
고객의 성향이나 서비스 이용 패턴을 반영하는
유의미한 시그널일 가능성 고려

데이터 전처리

◆ 변수 삭제

Credit_Limit & Avg_Open_To_Buy

- (Avg_Open_To_Buy = Credit_Limit - Total_Revolving_Bal)라는 계산으로 만들어지는 **파생 변수**
- Avg_Open_To_Buy를 삭제 (관행에 따라)

Total_Amt_Chng_Q4_Q1 & Total_Ct_Chng_Q4_Q1

- 두 변수 모두 **최근 소비 변화**를 나타낸다.
- 보통 금액 변화가 이탈률 설명력이 큰 경우가 많다고 하여, Total_Ct_Chng_Q4_Q1를 삭제

데이터 전처리

◆ 파생 변수 추가

```
# 파생변수 생성
# 거래 1회 평균 금액
df['avg_trans_amt'] = df['total_trans_amt'] / df['total_trans_cnt']

# 월 평균 거래 횟수
df['monthly_trans'] = df['total_trans_cnt'] / df['hold_month']

# 카드 의존도
df['spending_ratio'] = df['total_trans_amt'] / df['credit_limit']

# 활동 점수
df['activity_score'] = df['total_trans_cnt'] * (1 - df['inactive_12m']/12)
```

데이터 전처리

◆ 파생 변수 추가

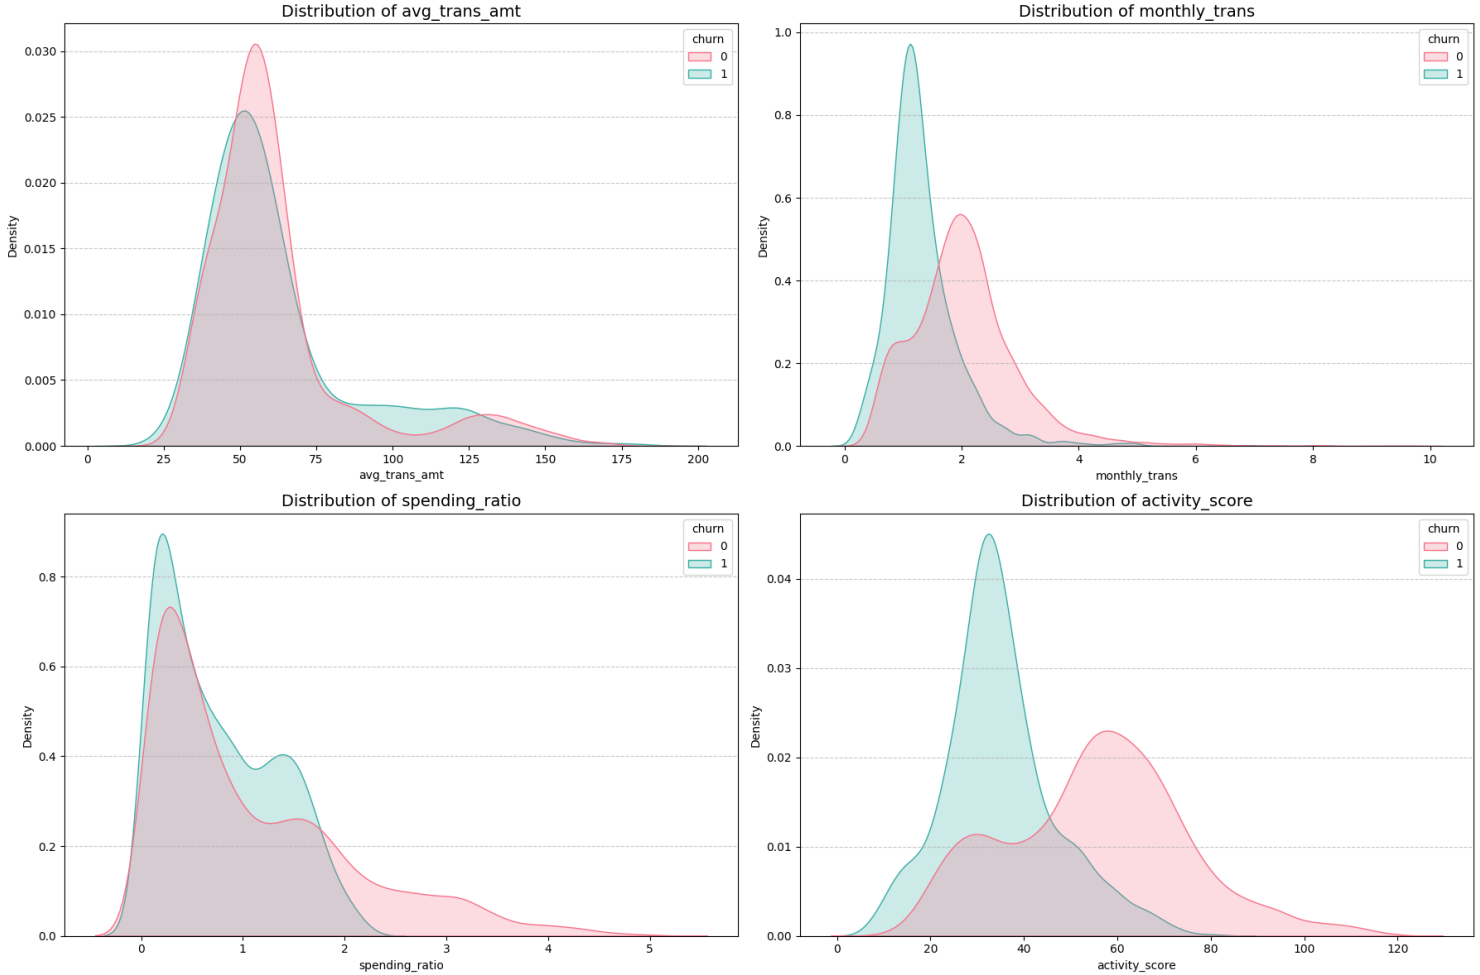

모델링 및 모델 평가

◆ 모델 선정 과정

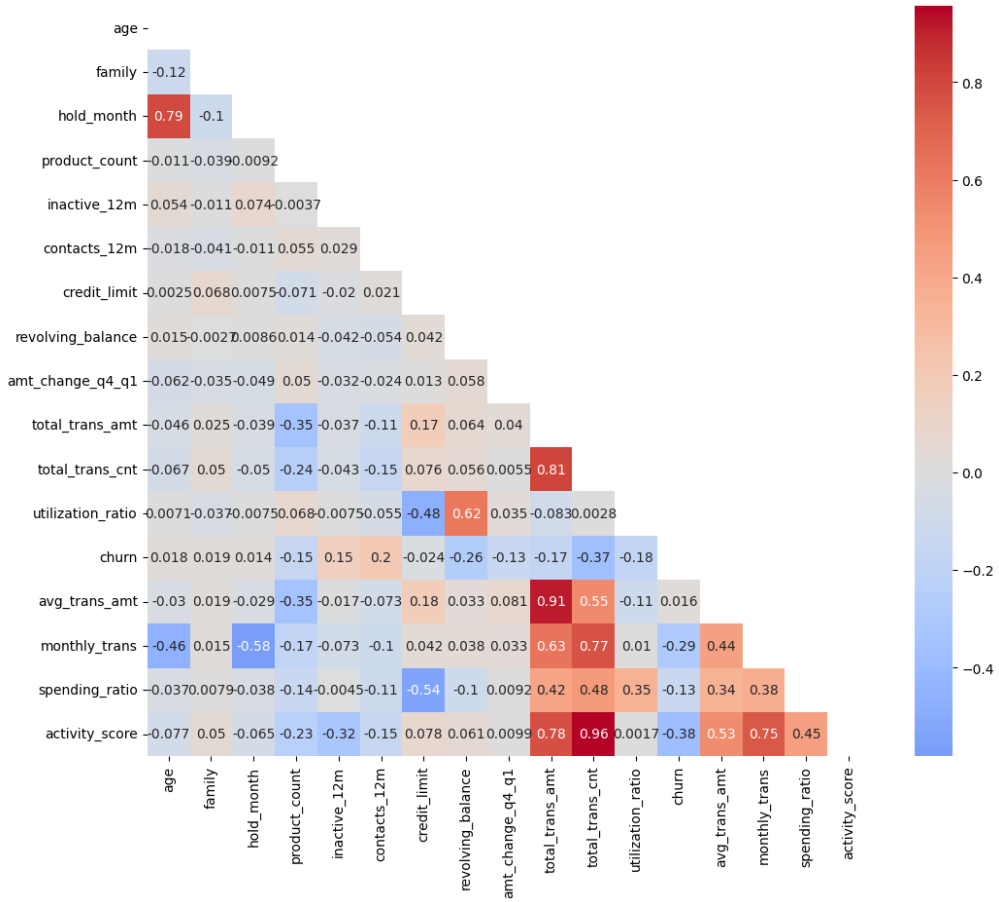

	feature	VIF
10	total_trans_cnt	805.642809
16	activity_score	708.578838
2	hold_month	107.300539
0	age	87.562205
13	avg_trans_amt	78.485595
9	total_trans_amt	59.580843
4	inactive_12m	49.536419
14	monthly_trans	38.103961
8	amt_change_q4_q1	13.265125
7	revolving_balance	8.428249
3	product_count	8.101105
11	utilization_ratio	6.945705
15	spending_ratio	6.851054
5	contacts_12m	6.159742
1	family	4.344399
6	credit_limit	4.240040
12	churn	1.877525

모델링 및 모델 평가

◆ 모델 선정 과정

	feature	VIF
10	total_trans_cnt	805.642809
1	activity_score	107.578838
2	hold_month	107.300539
0	age	87.562205
13	avg_trans_amt	78.485595
9	total_trans_amt	59.580843
4	inactive_12m	49.536419
14	monthly_trans	15.103961
8	amt_change_q4_q1	12.365125
7	revolving_balance	8.428249
3	product_count	8.101105
11	utilization_ratio	6.945705
[illegible]	[illegible]	[illegible]
5	contacts_12m	6.159742
15	family	4.344399
6	credit_limit	4.240040
12	churn	1.877525

다중공선성

변수 간 강한 수학적 상관관계 다수 확인

> Tree 기반 앙상블 모델 선정

RandomForest, XGBoost, LightGBM

변수 간 상관관계가 높아도 특정 변수를 선택해 분할,
다중공선성에 상대적으로 강하다

◆ 모델 선정 과정

```
📊 Validation 셋 Recall: 0.7883

[Validation 셋 Classification Report]
              precision    recall  f1-score   support

           0       0.96      0.99      0.97      1700
           1       0.91      0.79      0.85       326

    accuracy                           0.95      2026
   macro avg       0.94      0.89      0.91      2026
weighted avg       0.95      0.95      0.95      2026
```

```
📊 [XGBoost] Validation 셋 Recall: 0.8620

[Validation 셋 Classification Report]
              precision    recall  f1-score   support

           0       0.97      0.99      0.98      1700
           1       0.92      0.86      0.89       326

    accuracy                           0.97      2026
   macro avg       0.95      0.92      0.94      2026
weighted avg       0.97      0.97      0.97      2026
```

```
📊 [LightGBM] Validation 셋 Recall: 0.8804

[Validation 셋 Classification Report]
              precision    recall  f1-score   support

           0       0.98      0.98      0.98      1700
           1       0.91      0.88      0.90       326

    accuracy                           0.97      2026
   macro avg       0.94      0.93      0.94      2026
weighted avg       0.97      0.97      0.97      2026
```

모델링 및 모델 평가

◆ 중요도 낮은 변수 삭제

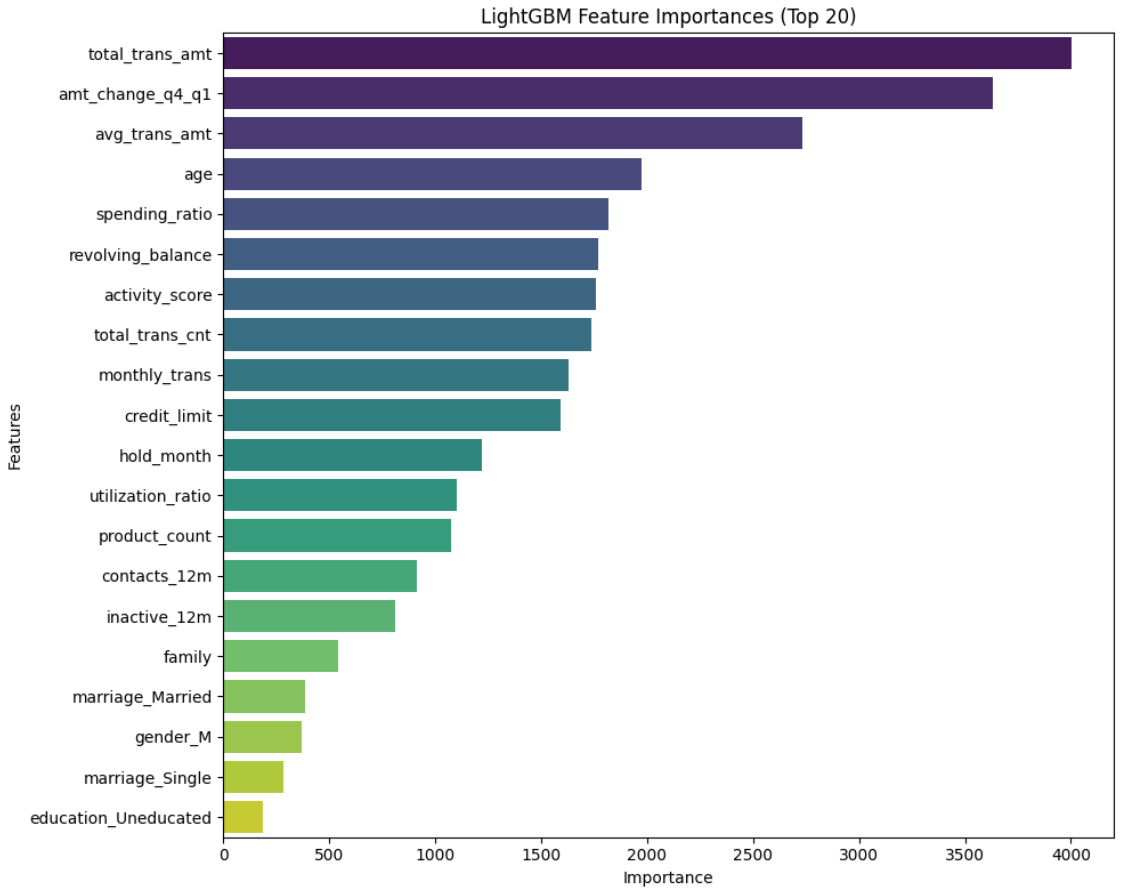

📊 [Slim 모델] Validation 셋 Recall: 0.8865

[Slim 모델 Validation 셋 Classification Report]

	precision	recall	f1-score	support
0	0.98	0.99	0.98	1700
1	0.93	0.89	0.91	326
accuracy			0.97	2026
macro avg	0.96	0.94	0.95	2026
weighted avg	0.97	0.97	0.97	2026

모델링 및 모델 평가

◆ 불균형 데이터 가중치 적용

```
# 1. 훈련 데이터의 불균형 비율(가중치) 계산
# 가중치 = (정상 고객 수) / (이탈 고객 수)
neg_count = (y_train == 0).sum()
pos_count = (y_train == 1).sum()
optimal_weight = neg_count / pos_count
```

```
[가중치 적용 모델 Validation 셋 Classification Report]
              precision    recall  f1-score   support

           0       0.98      0.99      0.98      1700
           1       0.92      0.90      0.91       326

    accuracy                           0.97      2026
   macro avg       0.95      0.94      0.95      2026
weighted avg       0.97      0.97      0.97      2026
```

모델링 및 모델 평가

◆ 모델 평가

```
🚀 [최종 Test Set 성능 평가 보고서] 🚀
--------------------------------------------------
✅ ROC-AUC Score : 0.9898
✅ PR-AUC Score  : 0.9575
--------------------------------------------------

[Classification Report]
              precision    recall  f1-score   support

           0       [illegible]  [illegible]  [illegible]  [illegible]
           1       0.90      0.88      0.89       325

    accuracy                           0.97      2026
   macro avg       0.94      0.93      0.94      2026
weighted avg       0.97      0.97      0.97      2026
```

ROC-AUC Score

임의의 이탈자와 정상 고객을 비교했을 때,
모델이 이탈 고객을 더 높은 위험도로 판단할 확률

PR-AUC Score

일탈 고객 탐지에서 Precision과 Recall 간 균형

모델링 및 모델 평가

◆ 모델 평가

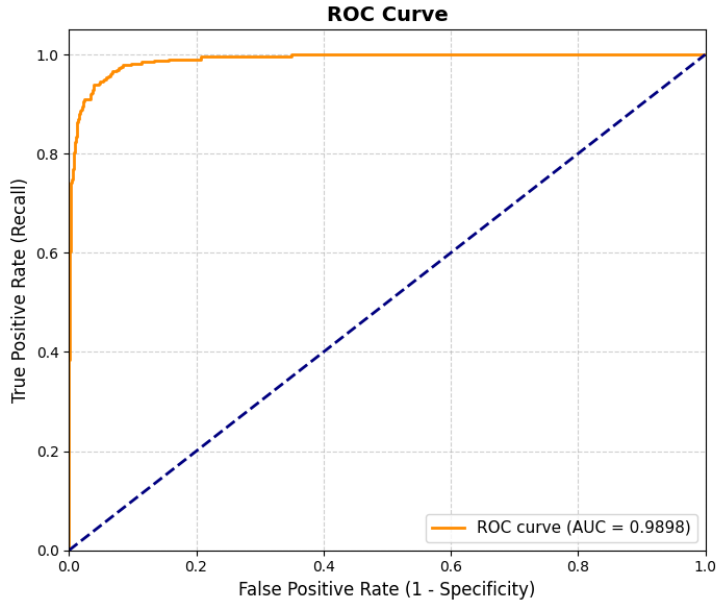

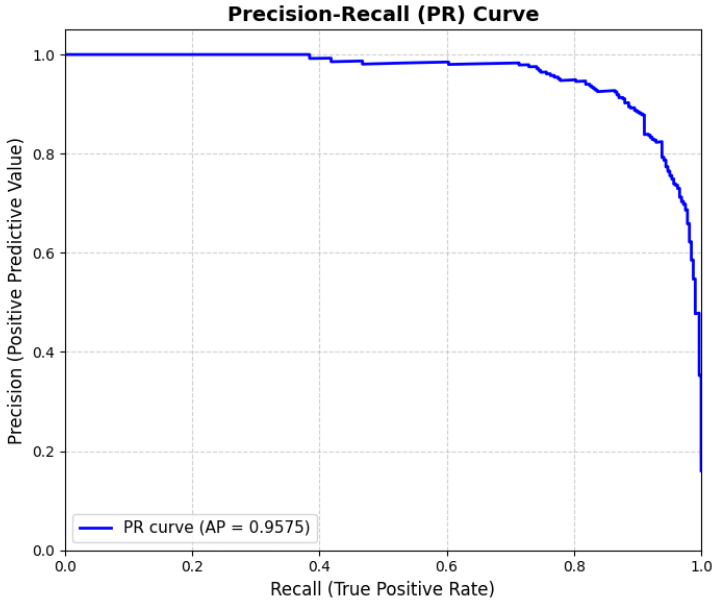

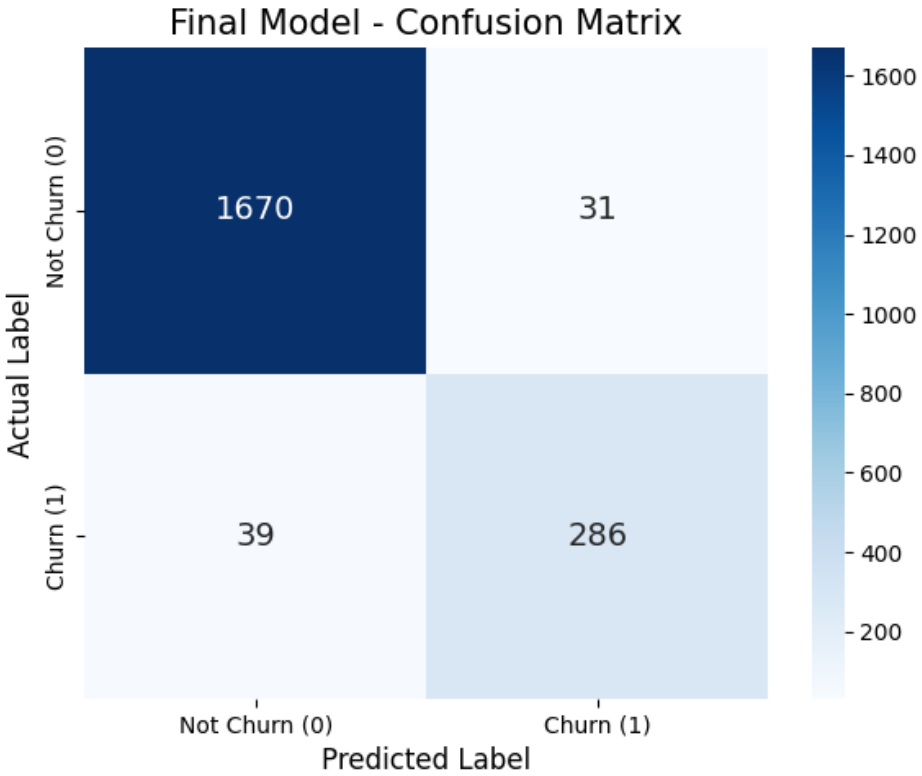

추가 분석 과정

◆ 모델 평가

비즈니스 목적에 따른 임계값(Threshold) 선택

```
# 임계값 시뮬레이션으로 정밀도와 재현율 균형 확인하기
# 1. 모델의 예측 확률값 가져오기 (클래스 1일 확률)
y_val_probs = lgbm_weighted.predict_proba(X_valid_slim)[:, 1]

# 2. 임계값 후보군 설정 (0.05부터 0.95까지)
thresholds = np.arange(0.05, 1.0, 0.05)
results = []

for thres in thresholds:
    # 임계값 적용
    y_pred_temp = (y_val_probs >= thres).astype(int)

    # 지표 계산
    prec = precision_score(y_valid, y_pred_temp)
    rec = recall_score(y_valid, y_pred_temp)
    f1 = f1_score(y_valid, y_pred_temp)
```

	Threshold	Precision	Recall	F1-Score
3	0.20	0.906061	0.917178	0.911585
11	0.60	0.926984	0.895706	0.911076
4	0.25	0.911043	0.911043	0.911043
10	0.55	0.924051	0.895706	0.909657
9	0.50	0.924051	0.895706	0.909657
2	0.15	0.893491	0.926380	0.909639
7	0.40	0.913313	0.904908	0.909091
6	0.35	0.913313	0.904908	0.909091
8	0.45	0.921136	0.895706	0.908243
1	0.10	0.879310	0.938650	0.908012
5	0.30	0.910494	0.904908	0.907692
12	0.65	0.929260	0.886503	0.907378
13	0.70	0.928571	0.877301	0.902208
16	0.85	0.940000	0.865031	0.900958
0	0.05	0.855956	0.947853	0.899563
14	0.75	0.928105	0.871166	0.898734
15	0.80	0.933775	0.865031	0.898089
17	0.90	0.955017	0.846626	0.897561
18	0.95	0.964664	0.837423	0.896552

추가 분석 과정

◆ 최종 모델

```
[Classification Report]
              precision    recall  f1-score   support

           0       0.98      0.98      0.98      1701
           1       0.88      0.90      0.89       325

    accuracy                           0.97      2026
   macro avg       0.93      0.94      0.94      2026
weighted avg       0.97      0.97      0.97      2026
```

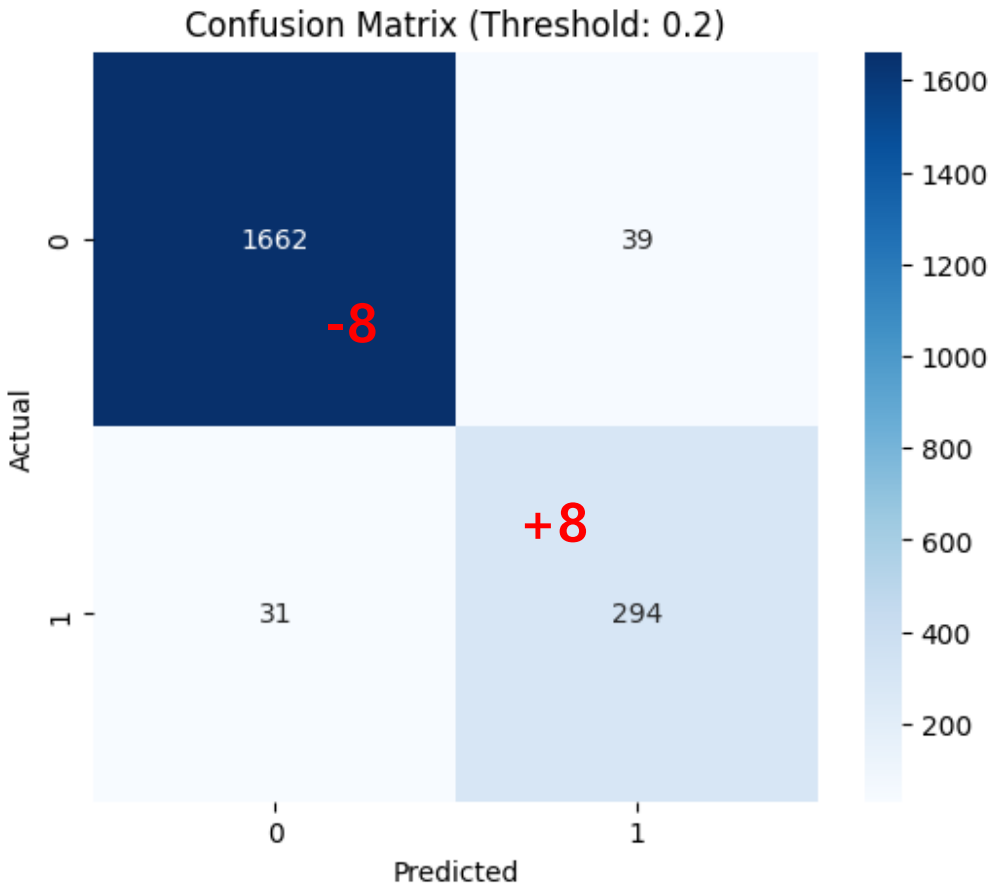

결과 요약 및 인사이트

◆ 분석 결과 요약

SHAP

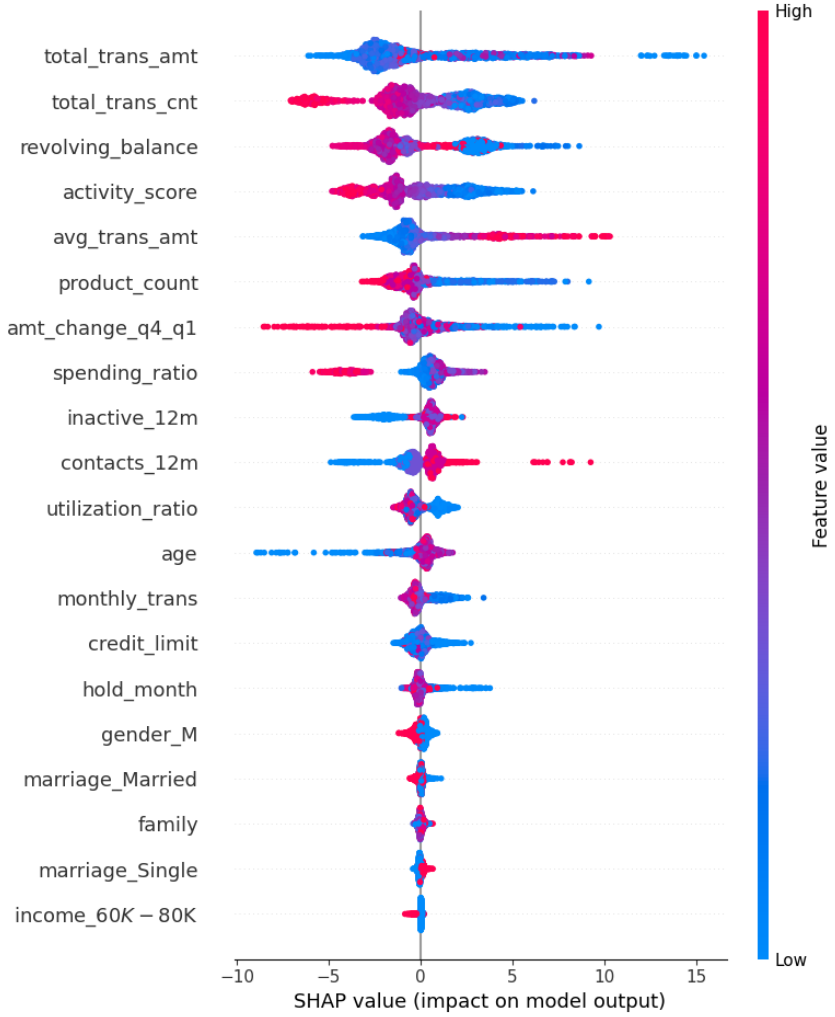

◆ 분석 결과 요약

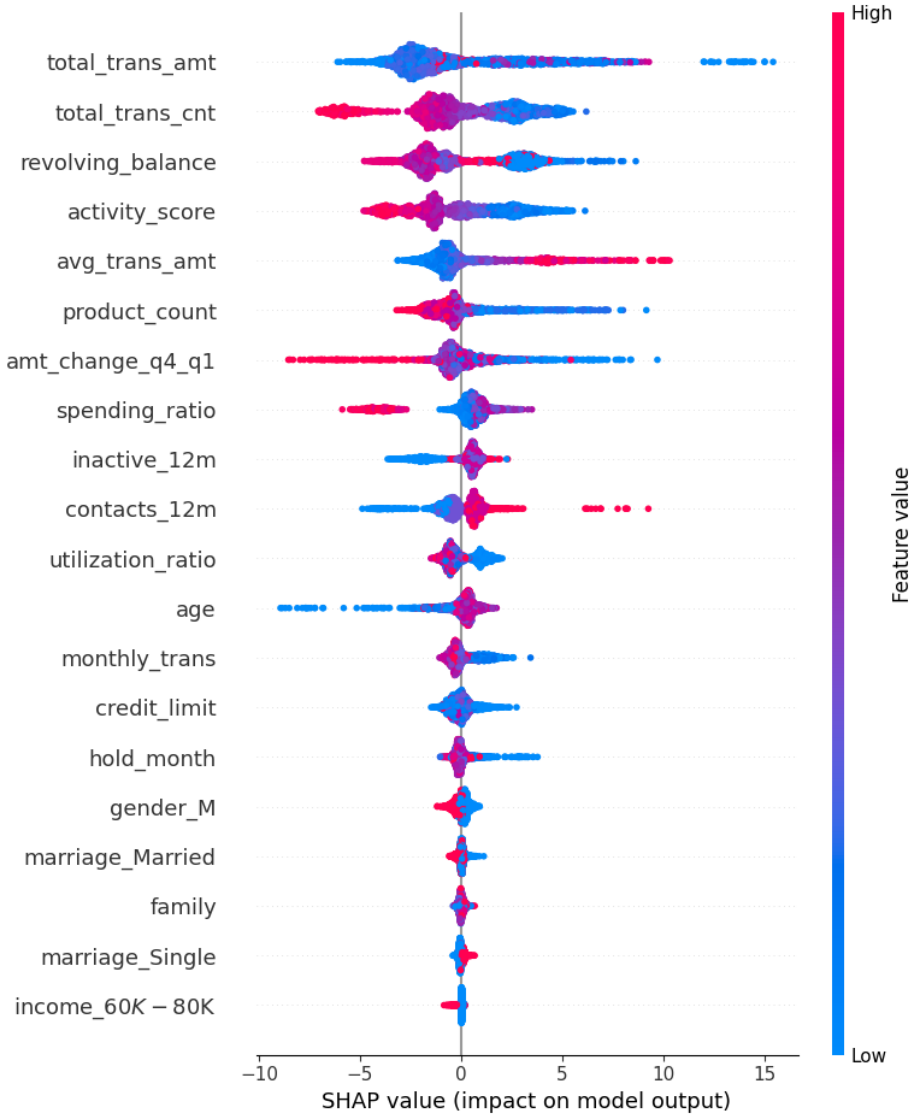

✅ 활동성 지표가 핵심

활동 관련 변수들이 최상단에 위치

"누구인가"보다 **"어떻게 행동하는가"**가 예측에 훨씬 중요하다.

✅ 부정적 신호 (High Risk 고객 특징)

- 거래 횟수 ↓ (total_trans_cnt ↓)
- 거래 금액 ↓ (total_trans_amt ↓)
- 최근 소비 감소 (amt_change_q4_q1 ↓)
- 고객센터 접촉 ↑ (contacts_12m ↑)
- 비활성 기간 ↑ (inactive_12m ↑)

"사용이 줄고 + 문제 접촉이 증가하는 고객" = 거의 이탈 직전

결과 요약 및 인사이트

카드 이탈은 고객 특성이 아닌 **'사용 감소 패턴 + 불만'**에서 발생한다

갑자기 떠나는 것이 아니라,

사용 감소 > 비활성화 > 불만 신호 증가라는 패턴을 통해

사전에 식별 가능하다!

향후 계획 및 개선 방향

1 시간 흐름을 반영한 분석

amt_change_q4_q1(전분기 대비 금액 변화) 변수가 상위 중요도를 보였다.

-> 단순히 현재 상태가 아닌 변화의 방향성을 파악할 수 있는
파생 변수를 활용한다던가, 시계열 특징을 추출한다면?

2 모델 성능 개선

Random Forest, XGBoost, LightGBM 3개 모델의 장점을 결합하는 **앙상블 기법(예: Stacking)**

3 세그먼트 기반 분석

인구통계학적 변수 기반으로 고객을 세분화해서 각 세그먼트별로 별도의 분석 또는 모델링을 수행한다면?

마무리